



UNIVERSIDAD AUTÓNOMA DE CHIHUAHUA



FACULTAD DE INGENIERÍA

INGENIERÍA EN CIENCIAS DE LA COMPUTACIÓN

Computo paralelo y distribuido

3.20 Proyecto Final

SISTEMA DISTRIBUIDO PARA ANÁLISIS DE SINIESTROS VIALES CON DATOS ABIERTOS DE INEGI

DOCENTE: JOSÉ SAUL DE LIRA MORAMONTES

EVELYN OYUKY TORRES ALANÍS 367868

ANA SOFIA LEDEZMA DÍAZ 367897

DAVID ALEJANDRO PÉREZ GONZÁLEZ 367759

FECHA: 27/05/2026

Introducción

En este proyecto se desarrolló una plataforma de análisis de accidentes viales en México utilizando herramientas de Big Data y procesamiento distribuido.

El sistema utiliza información histórica del dataset ATUS (Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas) proporcionado por INEGI.

El objetivo principal fue analizar patrones de accidentes, identificar zonas de riesgo y comparar el rendimiento entre procesamiento secuencial y procesamiento distribuido.

Para el desarrollo del proyecto se utilizaron tecnologías modernas como Python, Pandas, Ray, Parquet y Streamlit.

Objetivo General

Diseñar e implementar una aplicación distribuida utilizando Python y Ray para analizar accidentes viales en México y visualizar patrones de accidentes viales a partir de datos abiertos del INEGI.

Objetivos Específicos

- Descargar y preparar el dataset ATUS.
- Limpiar y transformar los datos.
- Convertir el dataset a formato Parquet.
- Implementar análisis secuencial con Pandas.
- Implementar procesamiento distribuido con Ray.
- Comparar tiempos de ejecución.
- Generar visualizaciones interactivas.
- Construir un dashboard para mostrar resultados.

Problema a Resolver

Las instituciones públicas y privadas requieren analizar grandes volúmenes de datos de accidentes para identificar patrones de riesgo y apoyar la toma de decisiones.

Cuando los datos históricos aumentan, el procesamiento secuencial puede volverse limitado.

El proyecto busca:

- Identificar estados y municipios con mayor número de accidentes.
- Detectar horarios y meses con mayor incidencia.
- Analizar causas más frecuentes.
- Relacionar accidentes con heridos y fallecidos.
- Evaluar el uso de procesamiento distribuido.

Descripción del Dataset

Se utilizó el dataset ATUS del INEGI.

Características principales

- Fuente: INEGI
- Cobertura: Nacional
- Formato original: CSV
- Registros analizados: 390,627 (año 2024)
- Variables utilizadas:
 - Estado
 - Municipio
 - Hora
 - Mes

- Causa del accidente
- Heridos
- Fallecidos

Arquitectura del Sistema

El sistema fue dividido en varias etapas:

1. Carga del dataset.
2. Limpieza y transformación.
3. Conversión a Parquet.
4. Procesamiento con Pandas.
5. Procesamiento distribuido con Ray.
6. Generación de gráficas.
7. Dashboard interactivo.

El procesamiento distribuido se realizó utilizando Ray localmente mediante workers paralelos.

Preparación y Limpieza de Datos

Durante esta etapa se realizaron:

- Conversión de tipos de datos.
- Eliminación de valores inválidos.
- Filtrado de horas incorrectas.
- Filtrado de meses inválidos.
- Conversión de columnas numéricas.
- Reemplazo de identificadores numéricos por nombres de estados.

Ejemplo:

- 8 → Chihuahua
- 9 → Ciudad de México

Esto permitió mejorar la interpretación de resultados.

Conversión a Parquet

El dataset original estaba en formato CSV.

Posteriormente se convirtió a formato Parquet.

Ventajas de Parquet

- Menor tamaño en disco.
- Lectura más eficiente.
- Formato columnar.
- Mejor rendimiento en Big Data.
- Mejor integración con procesamiento distribuido.

Aunque CSV fue más rápido en algunas pruebas pequeñas, Parquet está diseñado para escalar mejor en ambientes de Big Data.

Procesamiento Secuencial con Pandas

Se utilizó Pandas para realizar análisis estadísticos como:

- Conteo de accidentes por estado.
- Conteo por municipio.
- Accidentes por hora.
- Accidentes por mes.
- Causas más frecuentes.
- Cálculo de heridos y fallecidos.

Resultado

Tiempo aproximado: 0.014 segundos.

Pandas fue muy rápido debido a que:

- Está optimizado en lenguaje C.
- groupby es altamente eficiente.
- El dataset todavía es relativamente pequeño para Big Data real.

Procesamiento Distribuido con Ray

Ray permitió ejecutar tareas en paralelo.

Se implementaron funciones distribuidas utilizando:

`@ray.remote`

Cada worker procesó diferentes estados simultáneamente.

Resultado

Tiempo aproximado: 2.23 segundos.

Ray fue más lento debido al overhead de:

- Inicialización de workers.
- Distribución de tareas.
- Comunicación entre procesos.
- Serialización de datos.

Comparación de Rendimiento

Tecnología	Tiempo
Pandas	0.014 segundos
Ray	2.23 segundos

Interpretación

El procesamiento distribuido no siempre es más rápido.

Ray muestra ventajas principalmente cuando:

- El dataset es mucho más grande.
- Existen múltiples máquinas.
- Se realizan tareas muy pesadas.

Dashboard Interactivo

Se desarrolló un dashboard utilizando Streamlit.

El dashboard incluye:

- Métricas generales.
- Gráficas de accidentes.
- Top estados.
- Top municipios.
- Accidentes por hora.
- Accidentes por mes.
- Causas más frecuentes.
- Comparación Pandas vs Ray.

Las gráficas fueron generadas utilizando Plotly.

Resultados Obtenidos

Principales hallazgos

- Se identificaron los estados con mayor número de accidentes.
- Se detectaron municipios con alta siniestralidad.
- Se identificaron horarios de mayor riesgo.
- Se analizaron causas frecuentes.
- Se calcularon heridos y fallecidos.
- Se comprobó que Pandas fue más eficiente para este tamaño de datos.

Conclusiones

El proyecto permitió implementar una solución de análisis de datos utilizando herramientas modernas de Big Data.

Se logró:

- Aplicar procesamiento secuencial y distribuido.
- Analizar información real del INEGI.
- Generar visualizaciones interactivas.
- Comparar rendimiento entre tecnologías.

Finalmente, se comprobó que el procesamiento distribuido no siempre mejora el rendimiento en datasets medianos, pero sí ofrece ventajas importantes para proyectos de gran escala.

Bibliografía

- De Estadística Y, I. N. (n.d.). *Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS)*.
https://www.inegi.org.mx/programas/accidentes/?utm_source=chatgpt.com#microdatos
- *Catálogos entidades*. (n.d.).
http://www.dgis.salud.gob.mx/contenidos/intercambio/entidades_gobmx.html
- *pandas documentation — pandas 3.0.3 documentation*. (n.d.).
<https://pandas.pydata.org/docs/>
- *Welcome to Ray! — Ray 2.55.1*. (n.d.). <https://docs.ray.io/en/latest/index.html>
- *Streamlit Docs*. (n.d.). <https://docs.streamlit.io/>
- *Plotly documentation*. (n.d.). <https://docs.plotly.com/>
- *Documentation*. (n.d.). Parquet. <https://parquet.apache.org/docs/>